

SISTEMAS NEURO-FUZZY

NEURAL-FUZZY SYSTEMS

Stéphanie Lucchesi, Sandra Regina Monteiro Masalskiene Roveda

Campus Experimental de Sorocaba – Engenharia Ambiental – steh_l@hotmail.com, ISB.

Palavras chave: fuzzy, redes neurais, sistemas neuro-fuzzy.

Keywords: fuzzy, neural networks, neuro-fuzzy systems.

1. INTRODUÇÃO

Com o advento da lógica fuzzy, introduzida por Zadeh (1965), a modelagem ganha novas perspectivas já que constitui a base para o desenvolvimento de métodos e algoritmos de modelagem, permitindo a redução da complexidade e a solução de problemas não tratáveis pelas técnicas clássicas (GOMIDE, 1994). A matematização dos sistemas por essa via não pressupõe ferramentas matemáticas sofisticadas, mas ao contrário, a simplicidade na elaboração dos sistemas associada à possibilidade de tratamento linguístico das variáveis tem permitido soluções mais próximas à realidade, o que tem impulsionado consideravelmente as aplicações de lógica fuzzy. A literatura tem mostrado os sistemas de inferência fuzzy com aplicações já muito bem estabelecidas nas questões de engenharia associadas a controle de processos e ultimamente apresentam-se em contínuo desenvolvimento no âmbito dos problemas ambientais.

Além dos sistemas de inferência fuzzy, tem havido um interesse generalizado em outras técnicas de inteligência artificial tais como algoritmos genéticos e redes neurais, já que tornam possível simular a experiência humana durante a resolução de problemas por integrar o conhecimento descritivo, o conhecimento processual e a capacidade de raciocínio.

Algumas questões apontam caminhos na utilização das técnicas de inteligência artificial nos processos de modelagem. É importante ter claro que os sistemas fuzzy podem trabalhar com informações imprecisas (DUDA, 2000), apresentam resultados de fácil compreensão, no entanto não podem definir automaticamente as regras que utilizam para produzir o resultado. Por outro lado, as redes neurais possuem grande capacidade de aprendizado mas são limitadas no processamento de variáveis linguísticas (JANG, 1997).

Neste contexto apresentam-se os sistemas híbridos (SHING, 1993; ABRAHAM, 2001; MITRA, 2000), que fazem uso de pelo menos dois paradigmas de processamento de informações sob um único sistema, buscando integrar as vantagens de cada paradigma para resultar em modelos mais eficientes.

2. OBJETIVOS

Este trabalho tem como objetivo o estudo dos sistemas neuro-fuzzy, que são sistemas híbridos e utilizam os sistemas de inferência fuzzy para representar e processar o conhecimento de forma clara, de fácil interpretação com a capacidade de adaptação e aprendizagem das redes neurais.

3. MATERIAL E MÉTODOS

3.1 – Sistemas de Inferência Fuzzy

A lógica fuzzy estende a lógica tradicional com a introdução do conceito da verdade parcial, permitindo uma pertinência simultânea e parcial em vários conjuntos ao invés de uma inclusão total em um conjunto definido (ROSS, 2004). Assim, uma função de pertinência é uma curva que define o grau, de zero a um, com que cada ponto no espaço de saída é mapeado no conjunto fuzzy A . Usualmente é denotada por:

(1)

onde X é dito conjunto universo, que é sempre um conjunto clássico. Para cada $x \in X$, o valor μ_A

expressa o grau de pertinência do elemento x de X no conjunto fuzzy A , sendo que $\mu_A(x) = 0$ representa a não pertinência e $\mu_A(x) = 1$ representa a pertinência total de x ao conjunto fuzzy X .

Um subconjunto fuzzy é definido como um conjunto de pares ordenados

(2)

onde μ_A é a função de pertinência de x em A . A forma da função de pertinência é definida convenientemente.

As operações padrões de conjuntos fuzzy são: intersecção (operador *and*), união (operador *or*) e complementar de subconjuntos fuzzy (operador *not*). Dados dois ou mais conjuntos fuzzy, estas operações conectam esses conjuntos de modo que produzem um único subconjunto fuzzy, isto é, um agregado dos subconjuntos dados. Essas operações são essenciais na natureza da lógica fuzzy e estão definidas em Barros e Bassanezi (2006).

Esses conceitos são fundamentais para definir a metodologia dos controladores fuzzy ou sistemas baseados em regras fuzzy. A construção destes sistemas pode ser descrita em quatro etapas: fuzzificação, base de regras, inferência e defuzzificação. A fuzzificação envolve a definição das variáveis de entrada e saída, bem como de suas funções de pertinência. Na etapa seguinte, são elaboradas as bases de regras, que são um conjunto de regras linguísticas na forma: Se <antecedente> Então <consequente>, que descrevem a relação entre as variáveis de entrada e saída. A etapa de inferência é o mecanismo pelo qual as informações subjetivas definidas pela base de regras são avaliadas matematicamente. Finalmente, a defuzzificação consiste em transformar o valor fuzzy de saída em um valor numérico que não seja fuzzy, ou seja, num valor *crisp*. Detalhamento desta teoria pode ser consultado em Barros e Bassanezi (2006).

3.2 – Redes Neurais Artificiais

As redes neurais artificiais são consideradas boas técnicas computacionais para estimar funções, já que podem aproximar um comportamento desejado, sem a necessidade de especificar uma função particular, ou seja, são eficientes no tratamento de problemas nos quais a relação entre variáveis não é totalmente conhecida.

O neurônio artificial, ou nó neural, é um processador simples, que capta as informações exteriores ou de outros nós, toma uma única decisão sobre elas e passa o resultado para o próximo nó neural. As redes neurais são formadas pela combinação de muitos nós tendo assim a capacidade de tomar decisões complexas.

O *perceptron* é a forma mais simples de uma rede neural usada para a classificação de padrões ditos linearmente separáveis (HAYKIN, 1999). O *perceptron* recebe os sinais do mundo externo através de camada de entrada.

Matematicamente, temos:

(3)

na qual x representa o vetor de entrada de sinais. A matriz w é o peso dado para cada valor de sinal de entrada; os pesos w podem ser interpretados como o grau de acoplamento ou relevância daquela dimensão da matriz x para o *perceptron*. O termo m é o tamanho do vetor x de entrada. O somatório de todos os sinais é representado por v_k em que k é calculada através da função de ativação, generalizada na equação (4)

(4)

na qual ϕ representa a função de ativação. Existem diversos tipos e finalidades de funções de ativação, sendo que maiores detalhes a respeito podem ser encontrados em Haykin (1999) e Muller e Reinhardt (1990). A escolha de uma função de ativação afere o modo de disparo e interpretação dos sinais de entrada. Logo, o termo y_k representa a saída do neurônio k .

As redes neurais, quando aplicadas em sistemas inteligentes, tornam estes dinâmicos (MULLER; REINHARDT, 1990). Essa dinâmica é resultado da capacidade de aprendizado das redes neurais, proporcionado basicamente por um algoritmo de ajuste nos pesos w do *perceptron* na equação (3). Logo, matematicamente, quando uma rede neural aprende, ela está ajustando os pesos de conexões dos sinais de entrada. Cabe ressaltar que uma rede neural é especificada por sua topologia, pelas características dos nós e pelas regras de treinamento.

3.3 – Sistemas Neuro-Fuzzy

Um sistema neuro-fuzzy é um sistema fuzzy que usa um algoritmo de estratégias de aprendizado derivado do comportamento de redes neurais para encontrar os parâmetros determinados pelos conjuntos fuzzy. Este tipo de modelagem permite unir ao processamento linguístico de um sistema de inferência (SI) a capacidade de adaptação e aprendizagem das redes neurais. Uma das primeiras arquiteturas neuro-fuzzy denominada Sistema de Inferência Adaptativo Neuro-Difuso (ou *ANFIS – Adaptive Neural Fuzzy Inference System*), foi proposta por Jang (1993).

Uma arquitetura *ANFIS* típica possui cinco camadas de neurônios. Para exemplificar o funcionamento de um *ANFIS*, considere por simplicidade de apresentação, duas variáveis de entrada (x e y) e uma de saída (z). Na arquitetura apresentada, o SI embutido no *ANFIS* é do tipo *Takagi-Sugeno*. Nesse tipo de SI, proposto por Takagi e Sugeno (1985), as funções de pertinência das variáveis *consequentes* são funções das variáveis de entrada e não conjuntos difusos como no modelo tipo *Mamdani*. As regras têm, portanto, a seguinte forma geral:

$$R_i : \text{ Se } (x \text{ é } A_i) \text{ E } (y \text{ é } B_i) \text{ Então } (z_i = f_i(x,y)) \quad (5)$$

onde x e y são variáveis difusas de entrada sobre os universos de domínio U_x e U_y , e A_i e B_i são seus possíveis valores difusos sobre os mesmos universos de domínio. Neste trabalho, adotaram-se funções $f_i(x,y)$ do tipo linear afim, ou seja, $z_i = f_i(x,y) = p_i x + q_i y + r_i$, onde p_i , q_i e r_i são os parâmetros a serem ajustados.

Como em um SI, a *ANFIS* recebe as variáveis do mundo real no formato dos conjuntos clássicos. Através das iterações em suas camadas, os dados de entrada são transformados em variáveis lingüísticas, ao final retornando à variável em formato dos conjuntos clássicos. A seguir apresenta-se uma breve descrição de cada uma das camadas. Uma descrição mais detalhada pode ser vista em Jang (1993).

A **camada 1** é do tipo adaptativa com função definida por:

$$(6)$$

onde x é a entrada do nó i e A_i o valor difuso linguístico associado a esta função de nó, ou seja, O_i^I é a função de pertinência de A_i e especifica o grau de pertinência com que a entrada x satisfaz o valor linguístico A_i . As funções de pertinência do tipo Sino ou Gaussiana são geralmente adotadas. Os parâmetros desta camada são denominados *antecedentes*.

A **camada 2** é do tipo não-adaptativa e portanto, não possui parâmetros a serem ajustados. Nesta é executada uma função fixa de multiplicação dos sinais de entrada na camada, tendo como resultado o grau de aplicabilidade (w_i) de uma regra. Matematicamente, tem-se que:

$$(7)$$

A **camada 3** também é não-adaptativa. Nesta camada, é calculada em cada nó a razão entre a aplicabilidade da i -ésima regra (w_i) e o somatório das aplicabilidades de todo o sistema de regras. Matematicamente, tem-se:

(8)

onde são as saídas desta camada, denominadas *Aplicabilidades Normalizadas*.

A **camada 4** é do tipo adaptativa com função de ativação, matematicamente representada por:

(9)

onde são saídas da camada 3 e $\{p_i, q_i, r_i\}$ é o conjunto de parâmetros a ser ajustado. Estes parâmetros são denominados *parâmetros consequentes*.

A **camada 5** é do tipo não-adaptativa e composta por apenas um nó que calcula a saída final, como a soma de todos os sinais de entrada oriundos da camada 4. Matematicamente, tem-se:

(10)

Ao final deste processo, o *ANFIS* equivale a um SI, com a mesma vantagem de incorporar ao seu processo o conhecimento aproximado de um especialista. Além dessa estrutura existem outras variações de estrutura de um *ANFIS* que não serão abordadas neste trabalho.

4 – CONSIDERAÇÕES FINAIS

Este trabalho apresentou o estudo dos sistemas de inferência fuzzy, das redes neurais artificiais e de um modelo híbrido, integrando estas duas técnicas de inteligência Artificial., denominado sistemas neuro-fuzzy. A metodologia baseada em tais sistemas é bastante interessante por combinar as vantagens de cada uma das técnicas a saber: o processamento das variáveis linguísticas dos sistemas fuzzy e a atuação precisa e otimizada das redes neurais. Além disso, os sistemas neuro-fuzzy criam a base de regras automaticamente, eliminando a necessidade de especialistas para expressá-las.

Cabe destacar também que a combinação de diferentes técnicas, gerando modelos híbridos tem sido uma direção bastante promissora, pois possibilita sistemas mais versáteis para a modelagem de diversos problemas.

5 – REFERÊNCIAS

- ABRAHAM, A. **Neuro fuzzy systems: state of the art modeling techniques**. Lecture Notes in Computer Science. v.2084, p. 269-276, 2001.
- BARROS, L.C.; BASSANEZI, R.C. **Tópicos de Lógica Fuzzy e Biomatemática**. Campinas: UNICAMP/IMECC, 2006.
- DUDA, R.O.; HART, P.E.; STORK, D.G. **Pattern Classification 2/E**. New York, NY: Wiley Interscience, 2000.
- GOMIDE, F.A.C., GUDWIN, R.R. **Modelagem, Controle, Sistemas e Lógica Fuzzy**. SBA Controle & Automação, v.4, n.3, p. 97-115, 1994.
- HAYKIN, S. **Neural Networks: a comprehensive foundation, 2/E**. New York, N.Y.: Prentice Hall, 1999.
- JANG, J.S.R. **Anfis: Adaptive-network-based fuzzy inference system**. In: IEEE Transactions on Systems, Man and Cybernetics., 23, (3): 665-685, 1993
- JANG, J.S.R.; SUN, C.T.; MIZUTANI, E. **Neuro fuzzy and soft computing**. Upper Saddle River, NJ: Prentice Hall, 1997.
- MITRA, S.; HAYASHI, Y. **Neuro-fuzzy rule generation: survey in soft computing framework**. In: IEEE Transactions on Neural Networks, v11, 3, p. 748-768, 2000.

MULLER, B., REINHARDT, J.. **Neural newtorks: na introduction**. Berlin, Heidelerg, Springer Verlag, 1990.

ROSS, T. J. **Fuzzy logic with engineering applications**. John Wiley & Sons, New York, 2004.

SHING, J. and JANG, R. **ANFIS: Adaptative-network-based fuzzy inference system**. IEEE Trans on Systems, Man and Cybernetics, 23(3):665-685,1993.

TAKAGI, T. and SUGENO, M. **Fuzzy identification of systems and its application to modeling and control**. IEEE Transactions on Systems, Man and Cybernetics, 15, (1): 116-132, 1985.

ZADEH, L.A. **Fuzzy Sets**. Information and Control, v.8, p. 338-353, 1965.